
Post 1
APRENDE
ESTADÍSTICA
Variables y EDA

APRENDE ESTADÍSTICA
Variables y EDA

Antes de calcular nada, necesitas saber **qué tipo de datos** tienes. Trabajaremos con clientes de un banco para aprenderlo:

```
cliente = {
  "edad": 35,           # cuantitativa
  "ingreso": 4500,      # cuantitativa
  "segmento": "Premium", # cualitativa
  "mora": "No"          # cualitativa
}
```

`edad` cuántos años tiene

`ingreso` sueldo mensual en S/.

`segmento` Clásico, Premium, etc.

`mora` si debe o no cuotas

💡 Si no sabes qué tipo de variable tienes, no puedes elegir qué estadística calcular ni qué gráfico usar. Por eso es lo primero.

Tipos de variables · Escalas · EDA · Outliers

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Variables y EDA

1 Tipos de variables

¿Qué es una variable?
Cualquier **característica** que puede cambiar de una observación a otra. Cada columna de tu dataset es una variable.

Las dos grandes familias:

`Cualitativa`	**Categorías.** No se puede hacer operaciones matemáticas.	`segmento, mora`
`Cuantitativa`	**Números.** Puedes sumar, promediar, comparar.	`edad, ingreso`

Y cada una se divide:

`Nominal`	**Categorías SIN orden:** género, tipo de empleo
`Ordinal`	**Categorías CON orden:** riesgo bajo/medio/alto
`Discreta`	**Números enteros** (se cuentan): núm. productos
`Continua`	**Números con decimales** (se miden): ingreso

🔍 `Truco para distinguir:` pregúntate *¿tiene sentido calcular el promedio?* Si sí → cuantitativa. Si no → cualitativa.

DATAZO

Calcular la **media** de una variable nominal (ej: promedio de "tipo de empleo") no tiene sentido. Por eso clasificar primero te evita errores absurdos.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Variables y EDA

2 Dependiente vs independiente

¿Cuál es cuál?
La **dependiente** (Y) es lo que quieres predecir o explicar. Las **independientes** (X) son las que usas para predecirla.

Problema

Queremos predecir si un cliente caerá en **mora**. ¿Qué es Y y qué es X?

La Solución:

```
# Lo que quiero predecir = Y (dependiente)
Y = mora            # "Sí" o "No"

# Lo que uso para predecir = X (independientes)
X = [edad, ingreso, meses_antiguedad, segmento]
```

Y → la pregunta (dependiente) **X → las pistas (independientes)**

También se les llama: Y = **target / respuesta**. X = **features / predictores**.

🎯 **Analógicamente:** Y es la **pregunta** del detective (¿quién fue?). X son las **pistas** (huellas, horarios, testigos). Sin pistas no hay respuesta.

Y vs X en otros contextos:

🏥 **Salud** **Y:** diagnóstico · **X:** síntomas, edad, análisis

🛒 **Marketing** **Y:** ¿compra? · **X:** navegación, historial, edad

📚 **Educación** **Y:** aprobar o no · **X:** asistencia, notas, horas estudio

DATAZO

En un banco, la **Y** casi siempre es: ¿paga o no paga? (scoring), ¿se va o se queda? (churn), ¿es fraude o no? (detección). Todo lo demás son tus **X**.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Variables y EDA

3 Análisis Exploratorio (EDA)

¿Qué es un EDA?

Es **conocer tus datos antes de modelar**: ver su forma, detectar errores, entender patrones. Nunca construyas un modelo sin hacer EDA primero.

Los 3 niveles del EDA:

`Univariado` **Una variable a la vez.** Histograma, boxplot, tabla de frecuencias.

`Bivariado` **Dos variables juntas.** Scatter, boxplot por grupo, tabla cruzada.

`Multivariado` **Varias a la vez.** Heatmap de correlación, pairplot.

```
# EDA básico en Python (Pandas)
df.describe()      # resumen numérico
df.info()          # tipos y nulos
df.value_counts()  # frecuencias
```

❓ **Preguntas que responde el EDA:** ¿Cuál es la edad promedio? ¿Hay valores raros? ¿Los clientes Premium ganan más? ¿Faltan datos?

```
>>> df.describe()
              edad      ingreso
count   1000.00      1000.00
mean      34.12      4820.50   # promedio
std       10.45      2340.80   # dispersión
min       18.00       900.00
max       72.00    500000.00   # ¡outlier!
```

DATAZO

Saltarte el EDA es como operar sin radiografía. El 80% de los errores en modelos vienen de **no haber explorado los datos** antes.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Variables y EDA

4 Outliers y datos faltantes

¿Qué es un outlier?

Un dato que está **muy lejos del resto**. Puede ser un error o un caso real atípico. Distorsiona la media y puede arruinar modelos.

Cómo detectarlos:

```python
# Método IQR (rango intercuartílico)
Q1 = df["ingreso"].quantile(0.25)
Q3 = df["ingreso"].quantile(0.75)
IQR = Q3 - Q1
outliers = df[(df["ingreso"] < Q1 - 1.5*IQR) |
              (df["ingreso"] > Q3 + 1.5*IQR)]
```

💡 **Lee así:** Q1 y Q3 marcan el 25% y 75% de tus datos. Todo lo que caiga 1.5 veces más allá de ese rango se considera outlier.

`IQR` rango intercuartílico · `Z-score` desviaciones de la media · `Boxplot` visual

Datos faltantes:

```python
df.isnull().sum()  # cuántos nulos por columna
```

`eliminar` si son pocos (<5%) · `imputar` con media/mediana · `dejar NA` si el modelo lo soporta

DATAZO

Un cliente con ingreso de S/500,000 no es necesariamente un error: puede ser un CEO. El outlier se **investiga**, no se borra automáticamente.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Variables y EDA

5 Escalas de medición

¿Por qué importan?

La escala te dice **qué operaciones puedes hacer** con cada variable. No es lo mismo restar edades que restar códigos postales.

`Nominal`	**Solo clasificar.** No hay orden ni distancia.	`género, tipo`
`Ordinal`	**Clasificar + ordenar.** No puedes restar.	`riesgo A/B/C`
`Intervalo`	**Ordenar + restar.** El cero no es real.	`temperatura °C`
`Razón`	**Todo: sumar, dividir, proporciones.** El 0 es real.	`ingreso, edad`

👉 `Pregúntate para identificar la escala:`

¿Tiene `orden`? · ¿Puedo `restar`? · ¿El `0` significa "nada"?

En ciencia de datos bancario, casi todas tus variables numéricas son de `razón` (ingreso, monto, meses). Las categóricas son `nominales` u `ordinales`.

Qué puedes calcular con cada una:

Escala	Moda	Mediana	Media	Proporción
Nominal	✅	❌	❌	❌
Ordinal	✅	✅	❌	❌
Intervalo	✅	✅	✅	❌
Razón	✅	✅	✅	✅

DATAZO

Decir que un cliente con riesgo "C" es el **doble** de riesgoso que uno "B" es un error: la escala ordinal no permite eso. Solo sabes que C > B, no cuánto más.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA
Variables y EDA

El checklist que todo científico de datos sigue antes de modelar:

Paso	Acción	¿Para qué?
1. Clasificar	`Tipo de variable`	Saber qué estadística y gráfico usar.
2. Identificar	`Y vs X`	Definir qué predices y con qué.
3. Explorar	`EDA`	Conocer forma, patrones y errores.
4. Detectar	`Outliers + nulos`	Limpiar antes de modelar.
5. Verificar	`Escala`	No hacer operaciones inválidas.

Frases clave para recordar:

- Variable = cada **columna** de tu dataset.
- **Y** es lo que predices; **X** lo que usas para predecirla.
- EDA = conocer tus datos **antes** de modelar.
- Los outliers no se borran: se **investigan**.
- La escala define qué **operaciones** puedes hacer.

➧ **`Próximo post:`** estadística descriptiva (media, mediana, moda y desviación).

¡Guarda este post, dale like, compártelo y sígueme para el Post 2!

`#CienciaDeDatos · #Estadística · #Python`
`#AnalisisDeDatos · #DataScience · #EDA`

Milagros Espinoza Cunya