Post 2

APRENDE ESTADÍSTICA

Estadística Descriptiva

APRENDE ESTADÍSTICA
Estadística Descriptiva

Ya sabes qué variables tienes. Ahora toca **resumirlas en pocos números** que digan mucho:

```
ingresos = [1500, 2000, 3000, 4500, 500000]

# ¿Cómo describo estos 5 números?
media    = 102200   # suma / cantidad
mediana  = 3000     # valor del medio
moda     = -        # ninguno se repite
```

`media` el promedio clásico

`mediana` el valor del medio

`moda` el que más se repite

`std` qué tan dispersos están

Un solo número bien elegido puede resumir miles de clientes. Un mal elegido te hace tomar decisiones equivocadas.

Media | Mediana | Moda | Dispersión

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Estadística Descriptiva

1 Tendencia central

¿Cuál es el valor típico?

La tendencia central responde esa pregunta. Hay **tres formas** de hacerlo, y cada una cuenta una historia distinta.

Las tres medidas del centro:

`Media`	**Promedio.** Suma todos los valores y divide entre la cantidad.	`.mean()`
`Mediana`	**Valor del medio** cuando ordenas los datos de menor a mayor.	`.median()`
`Moda`	**El que más se repite.** Útil para variables cualitativas.	`.mode()`

```
# Mismo dataset, tres respuestas distintas
df["ingreso"].mean()     # 4820.50
df["ingreso"].median()   # 3200.00
df["segmento"].mode()   # "Clásico"
```

`Truco rápido:` si tus datos tienen outliers o son muy asimétricos, la `mediana` es más honesta que la media.

Guía rápida de decisión:

cuantitativa limpia → `media`

cuantitativa con outliers → `mediana`

cualitativa → `moda`

DATAZO

En un banco, la media y la mediana del ingreso pueden diferir en **miles de soles**. Reportar la equivocada cambia por completo cómo se ve a tus clientes.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Estadística Descriptiva

2 Media (promedio)

¿Cómo se calcula?
Suma todos los valores y divide entre la cantidad. Es el **centro de gravedad** de tus datos.

Fórmula y código:

```
# Media = (x1 + x2 + ... + xn) / n
ingresos = [2000, 3000, 4000, 5000, 6000]
media = sum(ingresos) / len(ingresos)   # 4000

# En Pandas:
df["ingreso"].mean()
```

La trampa: outliers la distorsionan

Sin outlier [2000, 3000, 4000, 5000, 6000] `media = 4000`

Con outlier [2000, 3000, 4000, 5000, 500000] `media = 102800`

Cuándo usarla: datos simétricos, sin valores extremos. **Cuándo evitarla:** cuando hay outliers o la distribución está sesgada.

```
>>> stats.describe([2000, 3000, 4000, 5000, 500000])
   mean:    102800     # inflada por el 500000
   median:    4000     # resiste el outlier
   diff:    +98800     # enorme distorsión
```

DATAZO

El "sueldo promedio" en un país casi siempre está **inflado** por quienes ganan muchísimo. Por eso los gobiernos reportan también la mediana.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Estadística Descriptiva

3 Mediana

¿Cómo se calcula?

Ordena tus datos de menor a mayor y toma el **del medio**. Si hay par, promedias los dos del centro.

Código paso a paso:

```
# Mismo dataset con outlier
ingresos = [2000, 3000, 4000, 5000, 500000]
ingresos.sort()                    # ya está ordenado
mediana = ingresos[2]              # posición central → 4000

# En Pandas (hace todo esto por ti):
df["ingreso"].median()
```

Comparando con el dato anterior: media = 102,800 vs mediana = 4,000. La mediana es la que **realmente describe** a la mayoría.

Dos casos según cantidad de datos:

Impar	**Toma el del medio.** Posición (n+1)/2.	[2,4,**6**,8,10]
Par	**Promedia los dos centrales.** (n/2) y (n/2+1).	[2,**4**,**6**,8] → 5

Cuándo es tu mejor opción:

hay outliers · distribución sesgada · reportar ingresos · reportar precios

DATAZO

La mediana se llama **robusta** porque no se deja mover por valores extremos. Un cliente millonario no cambia la mediana; a la media la dispara.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Estadística Descriptiva

4 Moda

¿Qué es?

El valor que **más veces aparece** en tus datos. Es la única medida de tendencia central que funciona con variables cualitativas.

Código:

```
# Variable cualitativa: tipo de segmento
df["segmento"].value_counts()
# Clásico   520
# Premium   310
# Gold      170

df["segmento"].mode()   # "Clásico"
```

Casos especiales:

Unimodal	Un solo valor domina. Lo más común.	`[A,A,A,B,C]`
Bimodal	Dos valores empatan. Puede indicar dos grupos distintos.	`[A,A,B,B,C]`
Sin moda	Ningún valor se repite. Común en variables continuas.	`[1,2,3,4,5]`

DATAZO

Si descubres que tu variable es **bimodal**, probablemente estás mezclando dos poblaciones distintas (ej: clientes de Lima y de regiones) y conviene analizarlas por separado.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Estadística Descriptiva

5 Dispersión

¿Qué tan parecidos son tus datos?

El centro no basta. Dos grupos con la misma media pueden ser **muy distintos**. La dispersión te lo dice.

`Rango`	**Max − Min.** Lo más simple, pero sensible a outliers.	`max() - min()`
`Varianza`	**Promedio de diferencias²** respecto a la media.	`.var()`
`Desv. estándar`	**Raíz de la varianza.** En las mismas unidades que tus datos.	`.std()`

```
# Dos equipos de ventas con misma media (5000)
estable  = [4800, 5000, 5200, 5000, 5000]
caotico  = [1000, 9000, 3000, 7000, 5000]

estable.std()   # 141   (datos agrupados)
caotico.std()   # 2828  (datos dispersos)
```

`Interpretación:` std pequeña significa que la mayoría de tus datos están cerca del promedio. std grande significa que varían mucho.

Regla práctica para interpretar la std:

std < `10%` media → muy agrupados

std ≈ `20-30%` media → normal

std > `50%` media → muy dispersos

DATAZO

Un modelo que predice el ingreso con std=5000 es **inútil** aunque acierte el promedio: cada predicción puede estar S/.5000 por arriba o por abajo del valor real.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Estadística Descriptiva

Tu guía para elegir la medida correcta en cada situación:

Medida	Código	Cuándo usarla
Media	`.mean()`	Datos simétricos, sin outliers.
Mediana	`.median()`	Datos con outliers o asimétricos.
Moda	`.mode()`	Variables cualitativas.
Rango	`max - min`	Idea rápida de la extensión.
Desv. std	`.std()`	Cuán dispersos están tus datos.

Frases clave para recordar:

- La media es el **centro de gravedad**; los outliers la mueven.
- La mediana es **robusta**: ignora los extremos.
- La moda es la **única** que sirve para cualitativas.
- Sin dispersión, el promedio **miente**.
- Siempre reporta **centro + dispersión** juntos.

→ **`Próximo post:`** visualización de datos (histograma, boxplot, scatter).

¡Guarda este post, dale like, compártelo y sígueme para el Post 3!

`#CienciaDeDatos · #Estadística · #Python`
`#AnalisisDeDatos · #DataScience · #Pandas`

Milagros Espinoza Cunya