Post 3

APRENDE ESTADÍSTICA

✦ Visualización de datos ✦

APRENDE ESTADÍSTICA
Visualización de datos

Ya resumiste tus datos en números. Ahora toca **verlos**: un buen gráfico cuenta en 2 segundos lo que una tabla te esconde.

```
# Imagínalo así:

Datos = tus números en bruto
Resumen = media, mediana, correlación
Gráfico = la historia detrás de esos números

# Los números te dan el "qué".
# El gráfico te da el "por qué".
```

- **histograma** la forma de 1 variable
- **boxplot** outliers y comparar grupos
- **scatter** relación entre 2 variables
- **heatmap** correlaciones de muchas

Dos datasets con los mismos números pueden verse **totalmente distintos** al graficarlos. Por eso siempre se grafica **antes** de modelar.

Histograma · Boxplot · Scatter · Heatmap

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Visualización de datos

1 ¿Qué gráfico uso?

La regla de oro:
El gráfico correcto depende de **cuántas variables** estás mirando y **de qué tipo** son (cuali o cuanti).

Según cantidad de variables:

`Univariado`	**1 variable sola.** Ver su forma, su centro, sus extremos.	`histograma, boxplot, barras`
`Bivariado`	**2 variables juntas.** Ver relación o comparación.	`scatter, boxplot x grupo, tabla cruzada`
`Multivariado`	**Varias a la vez.** Ver patrones globales.	`heatmap, pairplot, coord. paralelas`

Según tipo de variable:

- cuanti → `histograma, boxplot`
- cuali → `barras, pie`
- cuanti vs cuanti → `scatter`
- cuali vs cuanti → `boxplot x grupo`

`Flujo recomendado:` empieza por 1 variable (univariado) para entenderla; luego combina de 2 en 2 (bivariado); al final mira varias juntas (multivariado) para patrones globales.

DATAZO

Un error típico: usar un **pie chart** con más de 5 categorías. El ojo humano no distingue bien ángulos; las barras siempre ganan.

Milagros Espinoza Cunya

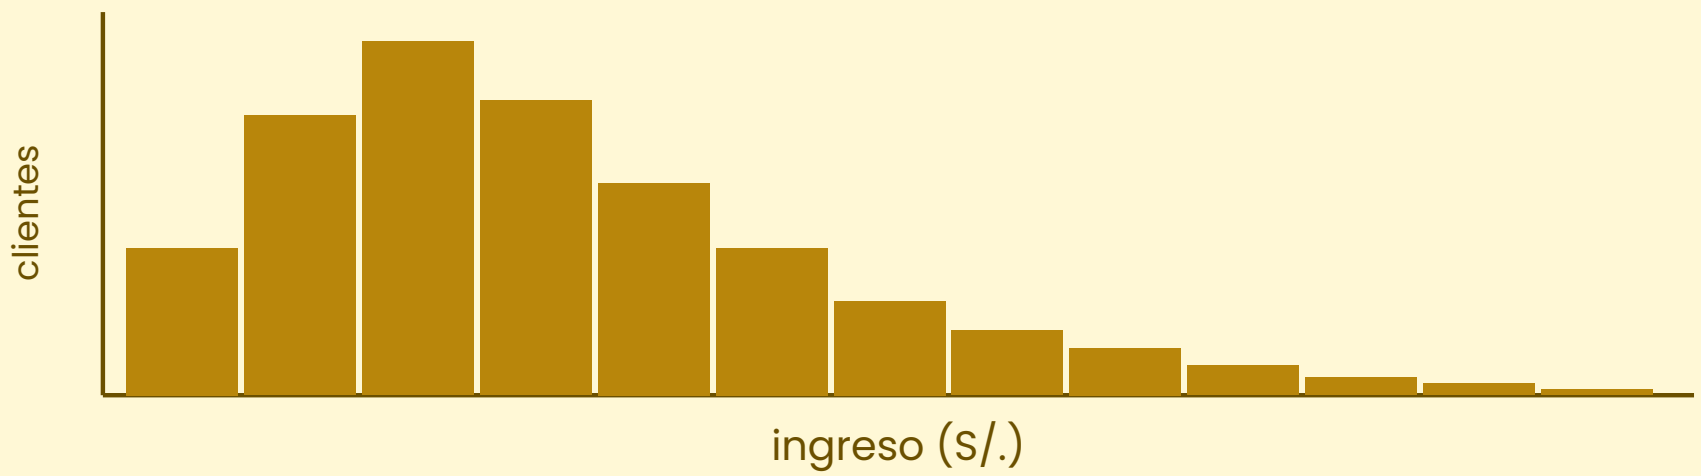
APRENDE ESTADÍSTICA

Visualización de datos

2 Histograma

¿Qué muestra?

La **forma de la distribución** de una variable cuantitativa: dónde se agrupan los datos, qué tan simétricos son, si hay colas largas.



Ingresos del banco → sesgado a la derecha

Qué buscar en él:

Simétrico	Forma de campana. Media y mediana coinciden.	`altura, puntajes`
Sesgado	Cola larga a un lado. La media se desplaza.	`ingresos, precios`
Bimodal	Dos picos. Posible mezcla de dos poblaciones.	`dos segmentos`

`Clave de los bins:` pocos → esconden la forma; muchos → muestran ruido. Prueba con 20–30 para empezar.

DATAZO

En banca, el histograma de ingresos casi siempre está **sesgado a la derecha**: muchos clientes ganan poco, pocos ganan mucho. Por eso la mediana es más informativa.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Visualización de datos

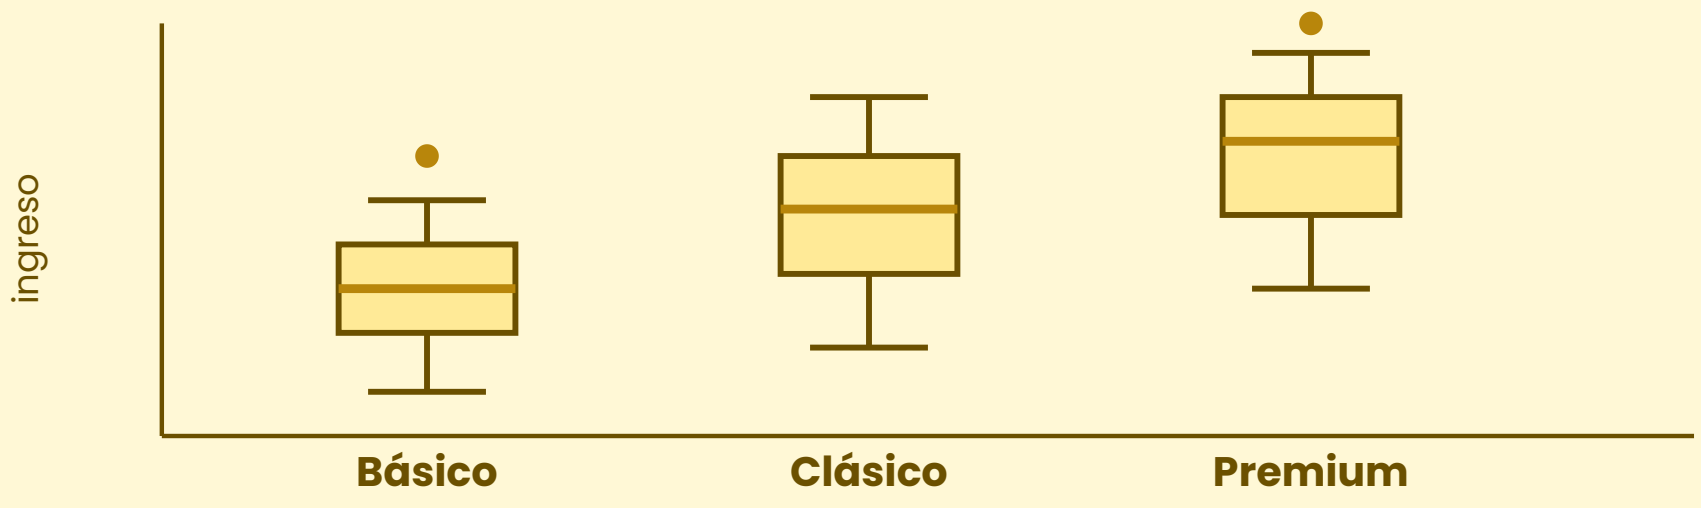
3 Boxplot

¿Qué muestra?

Un **resumen compacto en 5 números**: mínimo, Q1, mediana, Q3 y máximo. Y lo mejor: marca los **outliers** como puntos sueltos.

Anatomía:

`Caja` = Q1 a Q3 (50% central) · `Línea` = mediana · `Bigotes` = 1.5 × IQR · `Puntos` = outliers



Ingresos por segmento → cajas no se superponen

`Super poder:` con by= comparas la misma variable entre varios grupos y detectas diferencias de un vistazo.

Qué pistas te da:

caja `alta` → mucha dispersión · mediana `descentrada` → sesgo · muchos puntos fuera → `outliers`

DATAZO

Si al comparar ingresos por segmento ves que las cajas **no se superponen**, es evidencia visual fuerte de que los grupos realmente son distintos (previa prueba estadística).

Milagros Espinoza Cunya

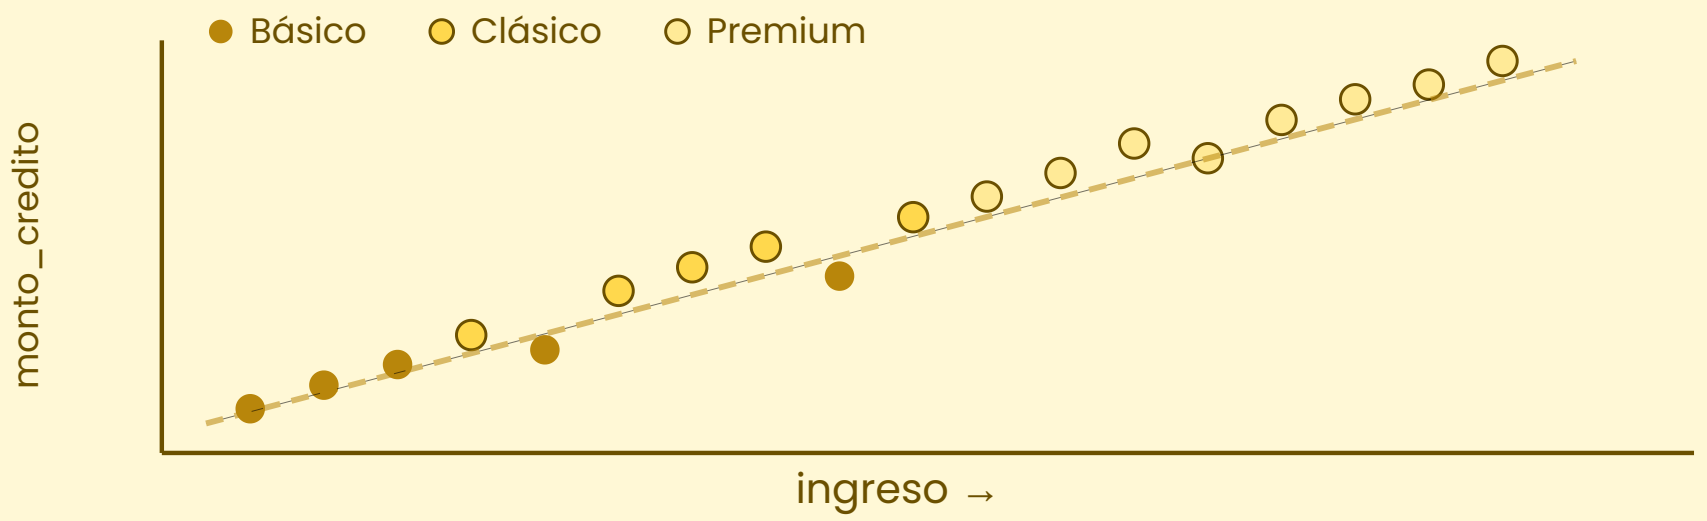
APRENDE ESTADÍSTICA

Visualización de datos

4 Scatter plot

¿Qué muestra?

La **relación entre dos variables cuantitativas**: cada punto es una observación con sus coordenadas (x, y).



A más ingreso, más crédito → relación lineal positiva

Patrones que puedes detectar:

`Lineal`	Los puntos siguen una recta. Correlación alta.	`cuanto más ingreso, más crédito`
`No lineal`	Siguen una curva. Correlación lineal baja pero hay relación.	`parabólica, exponencial`
`Sin relación`	Nube dispersa sin patrón. Correlación cercana a 0.	`ruido puro`

DATAZO

Antes de calcular correlaciones, **siempre dibuja el scatter**. Dos variables sin correlación lineal pueden tener una relación fuerte en forma de U o exponencial que el número no captura.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

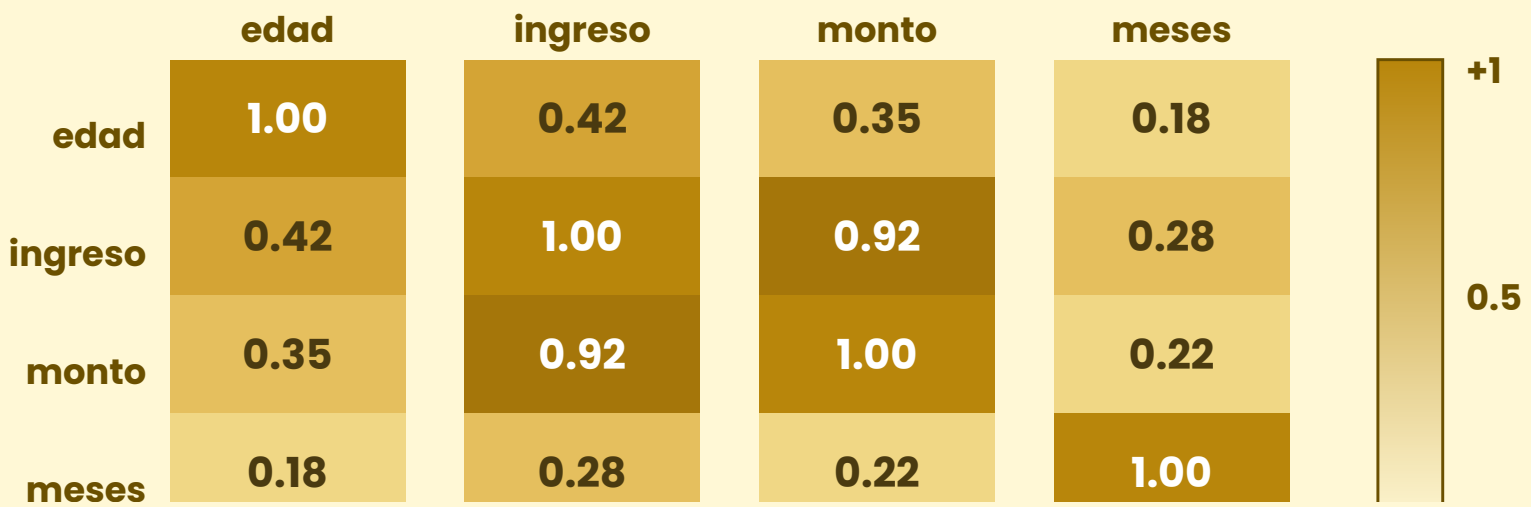
Visualización de datos

5 Heatmap

¿Qué muestra?
Una **matriz coloreada** donde cada celda es un número. El color (frío/caliente) resume el valor sin leer dígitos.

Dos usos clásicos:

`Correlaciones`	Entre todas las variables cuantitativas. Detectas redundancias.	`df.corr()`
`Tabla cruzada`	Dos variables categóricas. Ves qué combinaciones son frecuentes.	`pd.crosstab()`



ingreso vs monto = 0.92 → casi redundantes

`Lectura rápida:` color intenso → correlación fuerte (positiva o negativa). Color claro → no hay relación lineal. La diagonal siempre es `1.00` (cada variable consigo misma).

Escala de interpretación (|r|):

- 0.0 - 0.3 → `débil`
- 0.3 - 0.7 → `moderada`
- 0.7 - 0.9 → `fuerte`
- > 0.9 → `casi idéntica`

DATAZO

Si en el heatmap ves dos variables con correlación > **0.9**, estás midiendo lo mismo dos veces. Elimina una antes de modelar o tendrás problemas de multicolinealidad.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Visualización de datos

Tu guía para elegir el gráfico correcto según lo que quieres ver:

Gráfico	Para qué	Tipo de variable
Histograma	`forma de 1 variable`	cuantitativa
Boxplot	`outliers + comparar`	cuanti (por grupo)
Scatter	`relación entre 2`	cuanti vs cuanti
Barras	`frecuencias`	cualitativa
Heatmap	`muchas correlaciones`	cuanti o cruzada

Frases clave para recordar:

- Un gráfico correcto **reemplaza** a cien números.
- Elige según **tipo** y **cantidad** de variables.
- El boxplot detecta **outliers** sin que los calcules.
- Antes de correlacionar, **dibuja el scatter**.
- Un buen título y buenas etiquetas **valen oro**.

Errores comunes al visualizar:

ejes sin `etiquetar` · pie chart con `+5` categorías · colores que `no distinguen` · escalas sin `unidades`

→ `Próximo post:` probabilidad (clásica, condicional, Bayes).

¡Guarda este post, dale like, compártelo y sígueme para el Post 4!

Milagros Espinoza Cunya