Post 4

APRENDE ESTADÍSTICA

✦ Probabilidad ✦

APRENDE ESTADÍSTICA
Probabilidad

La probabilidad es el **lenguaje de la incertidumbre**. En banca, responde preguntas como ¿este cliente pagará? ¿esto es fraude?

```
# Lo que vamos a aprender:

P(evento)          = probabilidad clásica
P(A | B)           = probabilidad condicional
P(A | B) Bayes   = actualizar creencias
Sensibilidad       = ¿qué tan bueno detecta?
Especificidad      = ¿qué tan bueno descarta?
```

La probabilidad **no es intuitiva**. Nuestro cerebro no está diseñado para pensar en porcentajes, por eso Bayes es tan contraintuitivo.

Clásica | Condicional | Bayes | Fraude

Milagros Espinoza Cunya

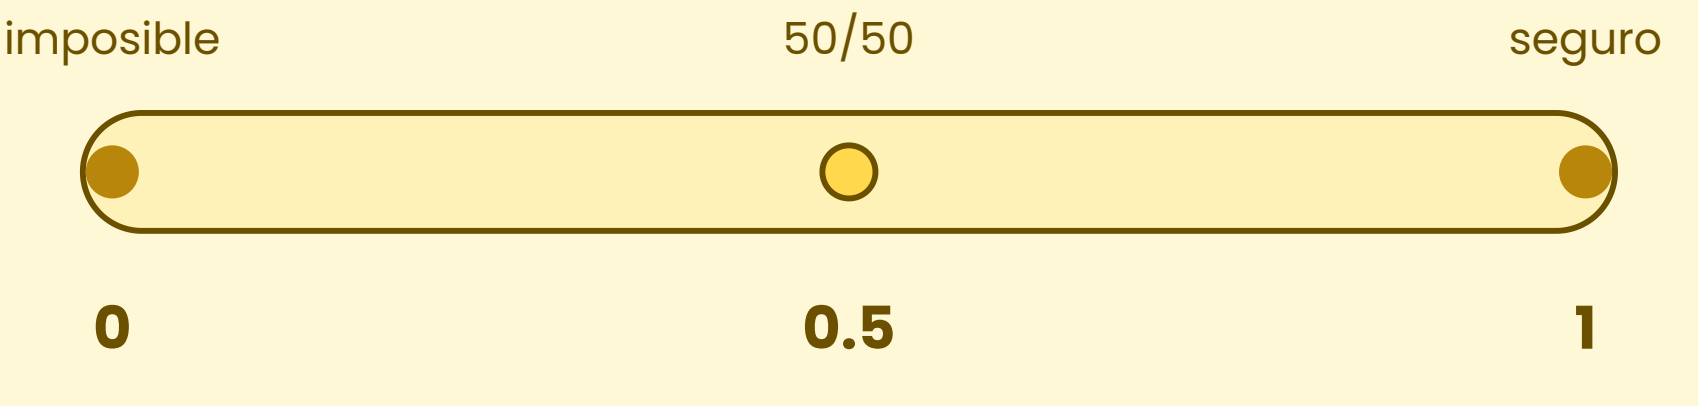
APRENDE ESTADÍSTICA

Probabilidad

1 Probabilidad clásica

¿Qué es?

Un número entre **0 y 1** que mide qué tan posible es que ocurra algo. 0 = imposible, 1 = seguro.



La escala de probabilidad

La fórmula básica:

```
P(evento) = casos favorables / casos totales
```

Dado: P(sacar 6) = `1/6`

Mora: P(mora) = `120/1000 = 0.12`

Propiedades que siempre se cumplen:

`Rango`	Toda probabilidad está entre **0 y 1**. Nunca negativa, nunca mayor a 1.
`Suma total`	Si sumas **todos** los resultados posibles, el total siempre es **1**.
`Complemento`	P(no A) = **1 − P(A)**. Si P(mora) = 0.12, P(no mora) = 0.88.

DATAZO

En un banco con 1000 clientes y 120 en mora, la probabilidad de mora es **0.12 (12%)**. Este número es la base de todo scoring crediticio.

Milagros Espinoza Cunya

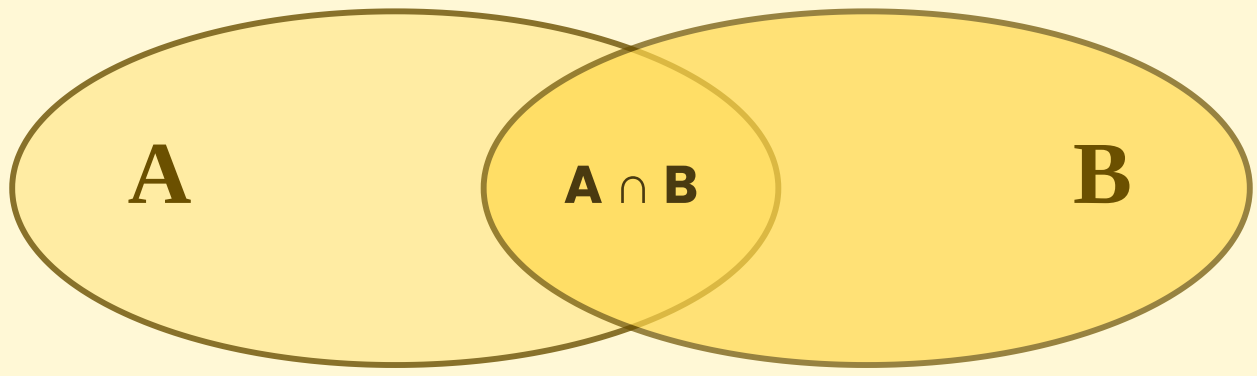
APRENDE ESTADÍSTICA

Probabilidad

2 Probabilidad condicional

¿Qué es?

La probabilidad de A **dado que** ya pasó B. Es como preguntar: "sabiendo esto, ¿ahora cuál es la probabilidad?".



$$P(A \mid B) = P(A \cap B) / P(B)$$

Ejemplo del banco:

`P(mora | independiente)` = de los clientes independientes, ¿qué porcentaje cae en mora? Normalmente es `mayor` que la P(mora) general.

Independencia:

A y B son `independientes` si P(A|B) = P(A)

Saber B `no cambia` la probabilidad de A

DATAZO

En banca, casi **nada es independiente**: edad, ingreso, tipo de empleo y mora están relacionados. Por eso los modelos usan todas las variables juntas.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Probabilidad

3 Teorema de Bayes

¿Para qué sirve?

Para **actualizar** una probabilidad cuando llega nueva información. Es el motor de los filtros de spam, los sistemas antifraude y el diagnóstico médico.

$$P(A|B) = P(B|A) \cdot P(A) / P(B)$$

La fórmula más famosa de la ciencia de datos

Qué significa cada parte:

`P(A)`	**Prior:** lo que sabías antes.	`creencia inicial`
`P(B|A)`	**Likelihood:** qué tan probable es la evidencia si A es cierto.	`verosimilitud`
`P(A|B)`	**Posterior:** tu creencia actualizada con la evidencia.	`resultado`

`Ejemplo rápido:` antes de ver tu historial de pagos, el banco cree que tienes 12% de probabilidad de mora. Después de ver que pagaste tus últimos 24 meses puntual, Bayes `actualiza` esa probabilidad a algo mucho menor.

DATAZO

Bayes **no reemplaza** tu conocimiento previo, lo **actualiza**. Esa es la diferencia entre un sistema que aprende y una regla fija.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Probabilidad

4 Sensibilidad y especificidad

¿Qué miden?

Qué tan bueno es un modelo (o test) para **detectar** lo que busca y **descartar** lo que no.

		Realidad: Fraude	Realidad: No fraude
	Alerta	**VP** verdadero positivo	**FP** falso positivo (falsa alarma)
	No alerta	**FN** falso negativo	**VN** verdadero negativo

Matriz de confusión: 4 casos posibles

`Sensibilidad` **De los fraudes reales, cuántos detecté.** VP / (VP+FN)

`Especificidad` **De los no-fraudes, cuántos pasé bien.** VN / (VN+FP)

DATAZO

Un sistema con 99% de sensibilidad suena perfecto, pero si tiene 90% de especificidad y los fraudes son **raros**, la mayoría de alertas serán falsas alarmas.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Probabilidad

5 La paradoja del fraude

La pregunta:
El sistema alerta fraude. ¿Cuál es la probabilidad **real** de que sea fraude? Intuitivamente dirías 99%. La realidad es muy distinta.

```
# Los datos
P(fraude) = 0.001          # 1 de cada 1000
Sensibilidad = 0.99        # detecta 99% de fraudes
Especificidad = 0.99       # descarta 99% de no-fraudes

# Aplicando Bayes:
P(fraude | alerta) = 0.09    # ¡solo 9%!
```

¿Por qué? Como el fraude es muy raro (0.1%), las falsas alarmas superan a los fraudes reales. De cada 100 alertas, solo 9 son fraude verdadero.

De 100,000 transacciones:

100	99,900 no-fraudes → 999 falsas alarmas
fraudes	99 fraudes detectados vs 999 falsas = **solo 9% real**

DATAZO

Esta es la razón por la que los bancos combinan **varias señales** antes de bloquear tu tarjeta. Un solo modelo con 99% de precisión no basta cuando el evento es raro.

Milagros Espinoza Cunya

APRENDE ESTADÍSTICA

Probabilidad

Tu guía rápida para dominar probabilidad en ciencia de datos:

Concepto	Fórmula	Para qué sirve
Clásica	`favorables / totales`	Medir qué tan posible es algo.
Condicional	`P(A|B)`	Probabilidad dado un contexto.
Bayes	`P(B|A)P(A)/P(B)`	Actualizar creencias con evidencia.
Sensibilidad	`VP/(VP+FN)`	Qué tan bien detecta el modelo.
Especificidad	`VN/(VN+FP)`	Qué tan bien descarta el modelo.

Frases clave para recordar:

- Probabilidad = **lenguaje** de la incertidumbre.
- Condicional = probabilidad **dado** un contexto.
- Bayes **actualiza** tus creencias con evidencia.
- Un evento raro + modelo bueno = **muchas falsas alarmas**.
- La intuición **falla**: siempre calcula.

→ `Próximo post:` distribuciones de probabilidad (normal, binomial, Poisson).

¡Guarda este post, dale like, compártelo y sígueme para el Post 5!

Milagros Espinoza Cunya