
Part 5
APRENDE PYTHON
Pandas

APRENDE PYTHON
Pandas

Es la herramienta #1 para analizar datos en Python. Convierte un archivo (como un Excel) en una **tabla inteligente** que puedes filtrar, ordenar y resumir en una línea.

```python
import pandas as pd

df = pd.read_csv("novelas.csv")
print(df)   # ¡toda la tabla, en 2 líneas!
```

💡 Recuerda que en la Parte 4 leíamos un CSV fila por fila. Pandas hace eso y **mucho más** en una sola línea. Aquí empieza la ciencia de datos de verdad.

DataFrame | Filtrar | Ordenar | Agrupar

Milagros Espinoza Cunya

APRENDE PYTHON
Pandas

1 El DataFrame

¿Qué es un DataFrame?

Es una **tabla** (como la de Excel): tiene filas y columnas con nombre. Se abrevia **df**. Es el corazón de Pandas.

La Solución:

```
import pandas as pd

df = pd.read_csv("novelas.csv")
df.head()   # muestra las primeras filas
```

`read_csv()` carga el archivo

`.head()` primeras filas (hasta 5)

`.shape` filas y columnas

Resultado:

```
   titulo   rating
0  Rubí     8.9
1  Teresa   9.0
2  Rebelde  9.8
```

👉 `.head()` muestra las primeras 5 filas; como nuestra tabla solo tiene 3 novelas, salen las 3. Cada fila va numerada (0, 1, 2) y cada columna con su nombre.

DATAZO

Ese **as pd** es un apodo: en vez de escribir "pandas" cada vez, escribes "pd". Es una convención que usa **todo el mundo**, así que acostúmbrate a verla.

Milagros Espinoza Cunya

APRENDE PYTHON

Pandas

2 Seleccionar columnas

¿Para qué?
Casi nunca necesitas TODA la tabla. Pandas te deja sacar **solo las columnas** que te interesan, por su nombre.

La Solución:

```
df["titulo"]          # una sola columna

df[["titulo", "rating"]]  # varias columnas
```

`df["a"]` una columna `df[["a","b"]]` varias (doble corchete)

Resultado:

```
0    Rubí
1    Teresa
2    Rebelde
```

👉 Este resultado es de la `primera línea`, `df["titulo"]`: Pandas devolvió los 3 valores de esa columna, dejando el resto de la tabla de lado.

DATAZO

¿Por qué doble corchete para varias? El de afuera dice "dame columnas", el de adentro es la **lista** de cuáles. Olvidar uno es el error #1 en Pandas.

Milagros Espinoza Cunya

APRENDE PYTHON

Pandas

3 Filtrar filas

¿Para qué?
Quedarte solo con las filas que cumplen una condición. Por ejemplo: solo las novelas con rating mayor a 9.

La Solución:

```
df[df["rating"] > 9.0]
```

Se lee de adentro hacia afuera: `df["rating"] > 9.0` marca cuáles cumplen; el `df[...]` de afuera se queda solo con esas filas.

Resultado:

```
   titulo   rating
2  Rebelde  9.8
```

👉 De las 3 novelas, solo `Rebelde` (9.8) supera el 9.0, así que Pandas devolvió esa única fila. Teresa (9.0) no entra porque no es `mayor` que 9.0.

DATAZO

En un banco, esto es filtrar clientes: **df[df["mora"] == "Sí"]** te da al instante todos los morosos. El mismo truco sirve para millones de filas.

Milagros Espinoza Cunya

APRENDE PYTHON

Pandas

4 Ordenar datos

¿Para qué?

Ver tus datos de mayor a menor (o al revés): las novelas mejor calificadas primero, los clientes con más deuda arriba.

La Solución:

```
df.sort_values("rating", ascending=False)
```

`"rating"` por qué columna ordenar

`False` de mayor a menor

`True` de menor a mayor

Resultado:

```
   titulo   rating
2  Rebelde  9.8
1  Teresa   9.0
0  Rubí     8.9
```

👉 Ordenó de mayor a menor rating: Rebelde (9.8) arriba, Rubí (8.9) al final. Fíjate que los números de fila ya no van 0,1,2: siguen pegados a su dato original.

DATAZO

ascending=False literalmente dice "ascendente = falso", o sea descendente (de mayor a menor). Es lo que usas para rankings: top ventas, top morosos, top clientes.

Milagros Espinoza Cunya

APRENDE PYTHON

Pandas

5 Agrupar y resumir

¿Qué es groupby?
Agrupa filas que comparten algo y calcula un resumen por grupo. Es la **tabla dinámica** de Excel, pero en una línea.

La Solución:

```
df.groupby("segmento")["ingreso"].mean()
```

En palabras: **agrupa por segmento**, y de cada grupo calcula el **promedio del ingreso**.

Resultado:

```
segmento
Básico     3200.0
Premium    6850.0
```

👉 Juntó a todos los clientes Básico por un lado y Premium por otro, y mostró el ingreso promedio de cada grupo. Así comparas segmentos al instante.

DATAZO

Cambia **.mean()** por **.sum()**, **.count()** o **.max()** y obtienes otro resumen. Esta sola línea reemplaza horas de trabajo manual en Excel.

Milagros Espinoza Cunya

APRENDE PYTHON
Pandas

Tu primer kit de Pandas para analizar datos:

Para...	Usas	¿Qué hace?
Cargar datos	`pd.read_csv()`	Abre un archivo como tabla (DataFrame).
Ver columnas	`df["col"]`	Saca solo las columnas que quieres.
Filtrar filas	`df[df["x"]>n]`	Se queda con las que cumplen la condición.
Ordenar	`.sort_values()`	De mayor a menor (o al revés).
Resumir	`.groupby()`	Agrupa y calcula por grupo.

¡Guarda este post, dale like, compártelo y sígueme para la Parte 6!

Milagros Espinoza Cunya